

Benchmark de Bibliotecas de Processamento de Dados: Uma Avaliação Experimental de Desempenho em Ambientes com Recursos Limitados

Denilson Silva Lima¹, Emerson Neves dos Santos¹,
Felipe Andrade dos Santos Carvalho¹, Maiko André Antunes de Sousa¹

¹Tecnologia em Análise e Desenvolvimento de Sistemas
Instituto Federal de Educação, Ciência e Tecnologia Baiano, Campus Guanambi
Guanambi-BA, Brasil

{email: denisilvalima536.com, emerson.santos,

felipebaiano04, maikosousa.tech}

@gmail.com

Abstract. *This experimental study presents a comparative performance benchmark among four of the main data processing libraries in Python: Pandas, Polars, DuckDB, and PySpark. The objective is to evaluate execution time efficiency and peak RAM memory consumption in hardware environments with limited resources. The evaluation was defined by a full factorial design using three dataset sizes (256MB, 512MB, and 1GB) and four fundamental analytical operations: filtering, aggregation, joining, and sorting. To ensure measurement stability and resource isolation integrity, each test was executed independently using individual subprocesses, preceded by a warmup phase. The results indicate significant trade-offs among the tools: Pandas exhibits simplicity but low scalability and a high risk of Out-Of-Memory (OOM) failures; Polars and DuckDB stand out for their high processing efficiency and optimized resource management; while PySpark, although robust, imposes considerable initialization overhead in restricted environments.*

Resumo. *Este estudo experimental apresenta um benchmark comparativo de desempenho entre quatro das principais bibliotecas de processamento de dados em Python: Pandas, Polars, DuckDB e PySpark. O objetivo consiste em avaliar eficiência em tempo de execução e o consumo máximo de memória RAM em ambientes de hardware com recursos limitados. A avaliação foi delimitada por um planejamento fatorial completo utilizando três tamanhos de conjuntos de dados (256MB, 512MB e 1GB) e quatro operações analíticas fundamentais: filtragem, agregação, junção e ordenação. Para garantir a estabilidade das medições e a integridade do isolamento de recursos, cada teste foi executado de forma estanque por meio de subprocessos individuais, antecidos por uma etapa de aquecimento (warmup). Os resultados indicam trade-offs significativos entre as ferramentas: o Pandas exibe simplicidade mas baixa escalabilidade e alto risco de falha por falta de memória (OOM); o Polars e o DuckDB destacam-se pela alta eficiência de processamento e gerenciamento otimizado de recursos; enquanto o PySpark, embora robusto, impõe um overhead considerável de inicialização em ambientes restritos.*

1. Introdução

O processamento de dados desempenha papel essencial em áreas como ciência de dados, engenharia de dados e análise computacional, envolvendo operações como limpeza, transformação, filtragem e agregação de informações [Moutinho et al. 2024]. Com o crescimento do volume de dados e da complexidade das aplicações, as bibliotecas de processamento passaram a exercer influência direta no desempenho, no consumo de memória e na escalabilidade das soluções computacionais [Cirillo and Galante 2025].

Nesse contexto, os benchmarks tornam-se importantes para avaliar experimentalmente diferentes ferramentas em cenários semelhantes de execução, permitindo analisar métricas como tempo de processamento, utilização de recursos e eficiência operacional [Cirillo and Galante 2025]. Além disso, diferentes bibliotecas adotam abordagens arquiteturais distintas, priorizando aspectos como simplicidade de uso, paralelismo, processamento otimizado ou escalabilidade distribuída. Assim, a comparação entre ferramentas como Pandas, Polars, DuckDB e PySpark possibilita compreender os principais trade-offs relacionados ao desempenho e ao consumo de recursos em diferentes cenários de uso.

1.1. Processamento de Dados em Ambientes com Recursos Limitados

Ambientes computacionais com recursos limitados de hardware, como restrições de memória RAM, CPU e armazenamento, impõem desafios severos ao processamento de volumes crescentes de dados, tornando a eficiência das bibliotecas um fator crucial para evitar falhas operacionais e garantir o desempenho adequado [Ourique 2024]. Diante desse cenário, avaliar o gerenciamento de memória, o paralelismo e a escalabilidade das ferramentas sob restrições permite identificar aquelas que apresentam o melhor equilíbrio entre velocidade de execução e consumo de recursos [Cirillo and Galante 2025]. Assim, estudos comparativos são fundamentais para orientar a escolha da solução mais adequada de acordo com o contexto de hardware disponível e o volume de dados a ser manipulado [Cirillo and Galante 2025].

1.2. Objetivos e Contribuições deste Estudo

Este estudo experimental contribui para orientar desenvolvedores e engenheiros de dados ao avaliar sistematicamente quatro abordagens arquiteturais distintas de manipulação de dados em Python: Pandas, Polars, DuckDB e PySpark. As principais contribuições deste trabalho consistem em:

- Avaliação fatorial completa em ambiente com isolamento estrito por subprocessos sob limitação real de hardware.
- Quantificação direta e comparativa do pico de consumo de memória física e tempo de execução analítico em três volumes de escala (256MB, 512MB e 1GB).
- Identificação clara dos trade-offs de desempenho e confiabilidade operacional.

2. Bibliotecas de Processamento de Dados

Esta seção apresenta uma visão geral das quatro bibliotecas avaliadas neste estudo, destacando seus objetivos de design, características arquiteturais e mecanismos para lidar com restrições de hardware.

2.1. Pandas

O Pandas é uma das principais bibliotecas de código aberto para manipulação e análise de dados estruturados em Python, amplamente reconhecida pela simplicidade de suas estruturas de *Series* e *DataFrame* e suporte a diversos formatos de arquivos [McKinney 2012, Wikipedia 2025].

Apesar de sua popularidade e maturidade, a biblioteca apresenta limitações significativas em cenários com grandes volumes de dados ou recursos computacionais restritos, decorrentes de seu modelo de processamento majoritariamente em memória (*in-memory*) e sem paralelismo nativo [Wikipedia 2025]. Ainda assim, sua estabilidade e ampla compatibilidade com o ecossistema Python a consolidam como uma referência indispensável para estudos comparativos de desempenho.

2.2. Polars

O Polars é uma biblioteca de processamento de dados desenvolvida em Rust para manipulação eficiente de tabelas, utilizando o formato colunar do Apache Arrow para otimizar o uso de memória e cache [Polars 2026]. Diferenciando-se do Pandas, foi projetado com foco em alto desempenho, oferecendo processamento paralelo nativo, execução vetorizada, avaliação preguiçosa (*lazy evaluation*) para otimização de consultas e suporte a processamento fora da memória (*out-of-core*) [NVIDIA 2026, Polars 2026]. Essas características minimizam o tempo de execução e a pegada de recursos computacionais, tornando o Polars ideal para cenários com grandes volumes de dados ou hardware restrito.

2.3. DuckDB

O DuckDB é um sistema de gerenciamento de banco de dados analítico (OLAP) de código aberto e embarcado (*in-process*), frequentemente associado ao conceito de “SQL-Lite para análises” pela simplicidade de uso integrada a consultas de alto desempenho [Foundation 2026a, Foundation 2026b].

Empregando armazenamento colunar, execução vetorizada e suporte nativo a formatos como CSV, Parquet e Apache Arrow, a ferramenta oferece alta eficiência em operações analíticas como agregações, filtros e junções [DuckDB 2026]. Um de seus principais diferenciais frente a soluções puramente em memória é a capacidade de processar volumes de dados que excedem a RAM disponível por meio de mecanismos de descarregamento em disco (*spill to disk*), o que o torna altamente relevante para ambientes computacionais limitados [Foundation 2026a].

2.4. Apache Spark (PySpark)

O PySpark é a interface em Python do Apache Spark, uma plataforma de código aberto voltada ao processamento de dados distribuídos em larga escala (*Big Data*) por meio de RDDs e DataFrames otimizados pelo mecanismo Catalyst. Ao contrário das demais ferramentas avaliadas, ele opera sobre a Máquina Virtual Java (JVM) e utiliza a arquitetura distribuída mestre-trabalhador (Driver-Executor) projetada para clusters.

Embora ofereça alta escalabilidade e tolerância a falhas, seu modelo de execução acarreta um elevado consumo basal de RAM e CPU decorrente da inicialização da JVM e da serialização de dados entre processos Python e Java. Essa característica torna essencial sua avaliação neste estudo para determinar os limites práticos e a viabilidade da plataforma em ambientes de nó único e recursos severamente limitados.

3. Desenvolvimento da Análise

Para realizar a medição e análise de desempenho entre as referidas bibliotecas de processamento de dados, foi desenvolvido um programa computacional escrito na linguagem Python, que executa nas quatro bibliotecas as operações de: filtragem, junção, agregação e ordenação. Em paralelo, o programa realiza a medição do consumo de recursos computacionais requisitados por cada biblioteca, a fim de gerar um arquivo JSON com os resultados de desempenho obtidos. A partir do arquivo gerado, inicia-se a análise estatística do benchmark.

O programa desenvolvido executa os seguintes passos: (1) prepara os dados de entrada de acordo com os tamanhos definidos para o teste; (2) itera pelas bibliotecas selecionadas; (3) para cada biblioteca, executa e afere o tempo e o consumo de memória máxima —na fase de carregamento do dataset; (4) executa iterações consecutivas das operações analíticas (filtragem, junção, ordenação e agregação) sob um isolamento estrito de sub-processos, registrando os picos de desempenho; e (5) salva e consolida estruturadamente todos os dados coletados em formato JSON.

3.1. Ambiente de Execução

Neste experimento, o ambiente de execução escolhido foi um notebook Dell Inspiron 15-3583, com as seguintes especificações: Processador Intel de 8ª geração (i7-8565U), 8GB de memória RAM DDR4 a 2400 MHz distribuídos em um slot SODIMM, SSD NVMe de 256GB M.2 PCIe, placa integrada Intel UHD Graphics 620 e sistema operacional Arch Linux versão minimal (sem interface gráfica). Esse hardware foi escolhido por representar um ambiente limitado para análise de dados, onde cada recurso é indispensável para possibilitar a execução das bibliotecas selecionadas de forma controlada.

3.2. Definição da Variável de Resposta, Fatores e Níveis

Para essa análise comparativa entre as bibliotecas de processamento de dados escolhidas, foram selecionadas duas variáveis de respostas: o tempo de execução (medido em segundos) e o consumo de memória (medido em Megabytes). Essas variáveis foram selecionadas por indicar métricas diretamente ligadas à limitação de hardware em dispositivos modestos, possibilitando assim uma comparação realista entre as referidas bibliotecas.

O comportamento dessas variáveis de resposta foi definido em função de três fatores de controle independentes, cada um com seus respectivos níveis:

- **Biblioteca selecionada:** contendo quatro níveis: Pandas, Polars, DuckDB e PySpark.
- **Tamanho do dataset:** submetido ao processamento, contendo três níveis: 256MB, 512MB e 1GB.
- **Operação analítica:** executada sobre os dados, dividida em quatro níveis: filtragem, agregação, junção e ordenação.

3.3. Execuções

O experimento adota o método de planejamento fatorial completo, abrangendo todas as combinações possíveis entre as quatro bibliotecas, os três tamanhos de dataset e as quatro operações analíticas, resultando em um arranjo de 48 cenários experimentais executados ao longo de 48 iterações consecutivas. Para assegurar uma comparação justa e fiel da eficiência computacional, o critério de parada foi definido estritamente pela quantidade total de registros processados, garantindo que todas as ferramentas executem exatamente a mesma carga de trabalho em cada teste.

Para mitigar o impacto de vazamentos de memória (*memory leaks*) ou acúmulo de cache, cada execução individual é isolada em um novo subprocesso do sistema operacional, permitindo registrar falhas de falta de memória (OOM) de forma segura sem interromper a estabilidade da suíte de testes. Adicionalmente, o fluxo experimental é dividido nas fases de carregamento (*load*) e de operação — que inclui uma iteração preliminar de aquecimento (*warmup*) para desconsiderar atrasos de inicialização de módulos e compilações JIT —, consolidando todos os tempos de execução e picos de uso de memória física (RAM) em um arquivo JSON para posterior análise estatística.

4. Resultados obtidos

Esta seção apresenta os resultados experimentais obtidos a partir da execução do benchmark projetado. As análises estão estruturadas em três vertentes principais: a escalabilidade temporal das operações analíticas, a eficiência no consumo de memória RAM (com ênfase no limite físico de hardware de 8GB) e a estabilidade das ferramentas ao longo de rodadas repetidas de teste.

4.1. Curva de Escalabilidade Temporal




Figura 1. Curva de Escalabilidade (Tempo de Execução em escala log) por Operação nas Diferentes Bibliotecas.

O desempenho de processamento de cada biblioteca foi avaliado para as quatro operações analíticas principais (filtragem, agregação, junção e ordenação) em função do aumento volumétrico dos dados (256MB, 512MB e 1GB). Os tempos médios das 48 rodadas estão expressos no gráfico de escalabilidade na Figura 1.

Observa-se que o PySpark exibe, sistematicamente, o maior tempo de processamento em todas as operações analíticas, situando-se entre 10^0 e $2 \cdot 10^1$ segundos. Esse comportamento reflete o custo computacional severo decorrente da inicialização de sua infraestrutura local (JVM, drivers e workers), além da necessária serialização de objetos entre os ambientes Python e Java. Em contrapartida, o Polars e o DuckDB mostram-se extremamente eficientes, mantendo tempos de execução subsegundo (frequentemente na escala de milissegundos, 10^{-2} s).

Na operação de filtragem, o Pandas apresenta excelente desempenho para volumes baixos (256MB), sendo ligeiramente mais rápido que o Polars e o DuckDB. Contudo, em operações mais complexas e pesadas como a junção (*join*), o Pandas demonstra baixa escalabilidade temporal: enquanto o Pandas requer cerca de 0,8 s para o processamento de 1GB, o Polars e o DuckDB executam a mesma carga em apenas 0,01 s, operando em uma velocidade aproximadamente 80 vezes superior.

4.2. Eficiência no Consumo de Memória RAM

Considerando que o ambiente computacional avaliado possui restrição física de hardware, a eficiência de alocação de memória é um fator crítico de confiabilidade operacional. A Figura 2 ilustra o consumo de pico de memória (RSS) das ferramentas para cada operação durante o processamento de 1GB.




Figura 2. Pico de Consumo de RAM (MB) por Operação no Dataset de 1024MB.

Os resultados evidenciam que o Pandas aloca constantemente em torno de 7.400 MB de RAM para executar qualquer transformação em 1GB de dados. Essa alocação estática e em memória física consome quase 93% da capacidade total de hardware disponível, colocando o sistema no limiar de falhas de falta de memória (Out-Of-Memory, ou OOM) em ambientes produtivos limitados.

Por outro lado, o DuckDB destaca-se como a ferramenta mais econômica, operando de forma constante na faixa de 600 a 650 MB. Isso é possibilitado por sua arquitetura analítica embarcada que emprega descarregamento dinâmico em disco (*spill-to-disk*) e processamento vetorizado por blocos. O Polars consolidou-se em uma posição intermediária eficiente, estabilizando seu pico de consumo em torno de 1.500 MB, enquanto o PySpark flutuou entre 700 MB e 1.700 MB.

4.3. Estabilidade e Dispersão de Desempenho

Para avaliar a consistência das ferramentas frente a flutuações e eventuais custos de aquecimento de compilação JIT ou Garbage Collection, a distribuição estatística das execuções no dataset de 1GB é sumarizada na Figura 3.




Figura 3. Boxplot de Distribuição do Tempo de Execução no Dataset de 1024MB.

O DuckDB obteve a menor mediana de tempo geral, apresentando apenas um *outlier* superior (cerca de 0,6 s) referente à primeira iteração analítica. O Polars apresentou a maior consistência de estabilidade geral, exibindo uma dispersão extremamente compacta e sem quaisquer *outliers*. O PySpark, por sua vez, demonstrou alta volatilidade e dispersão, com tempos oscilando entre 0,6 s e 7 s, além de registrar um pico atípico próximo a 20 segundos, o que reflete a instabilidade do Garbage Collection da JVM sob restrição severa de recursos.

5. Considerações Finais

Este trabalho apresentou uma análise comparativa experimental entre Pandas, Polars, DuckDB e PySpark em um cenário de hardware intencionalmente restrito.

Os resultados práticos sustentam que a escolha da biblioteca de processamento exerce um impacto profundo na eficiência e na resiliência do sistema. O Pandas, embora amplamente popular e de simples sintaxe, apresentou severas desvantagens em escalabilidade vertical e consumo de RAM, tornando-se uma escolha arriscada para datasets que se aproximam da capacidade física da memória RAM. O PySpark, desenhado para clusters distribuídos de larga escala, revelou-se ineficiente em cenários locais de nó único devido ao seu alto overhead computacional da JVM.

Em contrapartida, as bibliotecas Polars e DuckDB posicionam-se como soluções altamente recomendadas para engenharia de dados em ambientes limitados. Ambas combinam velocidades excepcionais com uma pegada de memória reduzida e otimizada (com destaque especial para a extrema economia de RAM do DuckDB). Como trabalhos futuros, sugere-se a ampliação do benchmark avaliando a influência de outros formatos de persistência de arquivos (como Parquet vs CSV) e a testagem de técnicas de processamento fora da memória (*out-of-core*) em conjuntos de dados multiescala que excedam 10GB.

Referências

- Cirillo, G. and Galante, G. (2025). Proposta de comparação da eficiência e escalabilidade de bibliotecas python para manipulação e análise de dados. In *Anais da XXV Escola Regional de Alto Desempenho da Região Sul*, pages 133–134, Porto Alegre, RS, Brasil. SBC.
- DuckDB (2026). Vectorized execution engine. [Online; accessed May-2026].
- Foundation, D. (2026a). Duckdb: An in-process SQL OLAP database management system. [Online; accessed May-2026].
- Foundation, D. (2026b). Duckdb documentation. [Online; accessed May-2026].
- McKinney, W. (2012). *Python for Data Analysis: Data Wrangling with Pandas, NumPy, and IPython*. O'Reilly Media.
- Moutinho, S. O. M., Martins, P. G. M., Alencar, D. F., and Coneglian, C. S. (2024). Ciência da informação e ciência de dados: convergências interdisciplinares. *Encontros Bibli: revista de biblioteconomia e ciência da informação*, 29:e99127.
- NVIDIA (2026). What is polars? [Online; accessed May-2026].
- Ourique, J. P. J. (2024). Análise experimental do desempenho de bibliotecas de ciência de dados em workflows com alto custo computacional. Trabalho de conclusão de curso (graduação), Universidade Federal do Rio Grande do Sul, Porto Alegre.
- Polars (2026). Polars: User guide. [Online; accessed May-2026].
- Wikipedia (2025). Pandas (software) — Wikipedia, the free encyclopedia. [Online; accessed May-2026].